

[참고] EM 알고리즘의 이해

권이태, 2025-03-31

1 Maximum Likelihood Estimation

우리가 n 개의 d 차원 데이터 $x_1, x_2, \dots, x_n \in \mathbb{R}^d$ 를 가지고 있다고 생각합시다. 또한 이는 어떠한 분포 F 를 따라 생성되는 i.i.d. d 차원 확률변수 $X_i, i = 1, 2, \dots, n$ 들의 **실현**(realization)이라고 합시다. F 는 어떠한 분포도 될 수 있으며, 정규분포 $N(\mu, \sigma^2)$, 균등분포 $U(a, b)$ 도 여기에 포함됩니다. 우리가 접해본 대부분의 분포는 이들처럼 유한 개의 모수들로 쉽게 그들을 표시할 수 있습니다. 따라서 우리는 F 가 특정한 분포를 따른다고 가정하면, 자료로부터 그 유한 개의 모수만 추정해냄으로써 전체 분포를 유추할 수 있습니다.

이제 편의를 위하여 F 가 정규분포 $N(\mu, \sigma^2)$ 이라 해 보겠습니다. 즉 $d = 1$ 입니다. 여러분이 잘 아시다시피, $\mu := \mathbb{E}[X_i]$ 의 적절한 추정량은 표본평균인

$$\hat{\mu} = \sum_{i=1}^n X_i$$

이 될 것이며, $\sigma^2 := \text{Var}(X_i)$ 의 적절한 추정량은 표본분산인

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \hat{\mu})^2$$

입니다. 이들 추정량이 여러 좋은 성질들을 가지고 있기 때문에 이들을 자주 사용하는데요. 이 글에서는 이들 추정량이 실제 모수 μ, σ^2 의 값인 경우 우리가 얻은 표본 $(X_1, X_2, \dots, X_n)$ 이 등장할 **가능도**(likelihood)가 가장 커지기 때문입니다.

가능도를 식으로 쓰면,

$$L(\mu, \sigma^2; x) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

처럼 실제 모수가 (μ, σ^2) 일 때 x_i 에서의 확률밀도함수들을 곱한 형태로 나타납니다. 이 가능도를 최대화하는 모수는, 로그함수가 증가함수임에 따라 로그가능도를 최대화하는 모수이기도 합니다. 따라서 양변에 로그를 씌워 로그가능도를 만들면,

$$\begin{aligned} l(\mu, \sigma^2; x) &= \sum_{i=1}^n \log\left(\frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)\right) \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} \end{aligned}$$

이 됩니다. 이제 이를 최대화하는 μ, σ^2 을 찾아 보겠습니다. 로그가능도가 미분 가능하기 때문에, 이들 모수는 l 을 미분했을 때의 미분계수를 0으로 만들어야 한다는 **일계조건**(F.O.C; First Order Condition)을 가지고 있습니다. 편의상 일계조건을 만족시키는 값이 가능도를 최대화된다고 가정해 보겠습니다. 먼저 양변을 μ 로 미분하면, 일계조건으로

$$\frac{\partial l}{\partial \mu} = \sum_{i=1}^n \frac{(x_i - \mu)}{\sigma^2} = 0$$

을 얻습니다. 둘째로 양변을 σ^{-2} 로 미분하면,

$$\frac{\partial l}{\partial \sigma^{-2}} = \frac{n}{2} \sigma^2 - \sum_{i=1}^n \frac{(x_i - \mu)^2}{2} = 0$$

역시도 일계조건이 됩니다. 둘을 연립하면, 로그가능도를 최대화하는 모수집합 $(\hat{\mu}^{\text{MLE}}, \hat{\sigma}^{2, \text{MLE}})$ 는

$$\hat{\mu}^{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\hat{\sigma}^{2, \text{MLE}} = \frac{1}{n} \sum_{i=1}^n (X_i - \hat{\mu}^{\text{MLE}})^2$$

를 얻습니다. 앞서 살펴본 평균의 추정량과는 일치하지만, 분산의 추정량과는 약간의 차이(분모가 n 이나, $n-1$ 이냐)가 있습니다. 물론 $n \rightarrow \infty$ 라면, 둘은 점근적으로 동일합니다. 이처럼 가능도를 최대화하는 모수의 추정량을 **최대가능도추정량**(MLE; Maximum Likelihood Estimator)라 부릅니다.

정규분포의 경우에는 수식을 통해 간편하게 최대가능도추정량을 구해낼 수 있습니다. 그런데 많은 경우, 차원이 커지거나 분포가 복잡해질수록 이처럼 수식을 통해 일계조건을 얻고, 이로써 최대가능도추정량을 얻는 것이 어려워집니다. 이러한 경우에는 앞서처럼 해석적(analytical)인 해법이 아니라, 수치적(numerical)인 방법을 통해 최대가능도추정량을 근사적으로 얻으려 합니다. 대표적으로는 F 가 정규분포가 아니라 t 분포를 따르는 상황 등을 고려할 수 있는데요, t 분포의 확률밀도함수는

$$f(x; \nu) = \frac{\Gamma(\frac{\nu+1}{2})}{\sqrt{\pi} \nu \Gamma(\frac{\nu}{2})} \left(1 + \frac{x^2}{\nu} \right)^{-\frac{\nu+1}{2}}$$

으로 그 모수 ν 의 최대가능도추정량을 찾으려면 고난이 예상되기 마련입니다.

이제 $d = 1$ 인 상태에서 F 가 정규분포가 아니라, 다른 분포들이라고 생각해 봅시다. 여기에는 모수 벡터 θ 가 있고, 이들로부터 얻은 가능도는 $L(\theta; x)$, 로그가능도는 $l(\theta; x)$ 입니다. 그렇다면 $\hat{\theta}^{\text{MLE}}$ 의 해를 찾기 위해서는,

$$\hat{\theta}^{\text{MLE}} = \operatorname{argmax}_{\theta \in \Omega} l(\theta; x)$$

라는 문제를 풀어야 합니다. 이때 Ω 는 θ 가 존재할 수 있는 모수공간으로, 정규분포에서는 $\mathbb{R} \times \mathbb{R}^+$ 였습니다. 이 문제를 푸는 수치적인 방법들은 F 가 가진 조건에 따라 정말 다양하지만, 여기에서는 가장 간단한 **Newton's Method**를 알아 보겠습니다. 앞서 우리가 살펴보았던 이 최대화 문제의 해를 찾는 다른 방법은 일계조건을 이용하는 것입니다. 즉

$$\frac{\partial l}{\partial \theta}(\hat{\theta}^{\text{MLE}}) = 0$$

임을 이용하자는 것입니다. 즉 이 경우 θ 의 최대가능도추정량은 $\frac{\partial l}{\partial \theta} = 0$ 의 근을 찾는 문제와 동일합니다. Newton's method는 이처럼 특정 방정식의 근을 찾기 위해 개발된 방법으로, 아래의 그림처럼 계속하여 업데이트해가면서 실제 근에 다가가는 방식으로 진행됩니다.




Figure 1: Newton's method의 모식도. Notation은 살짝 다를 수 있음. Source: Wikipedia

Newton's method에서는 먼저 적절한 초기값 $\theta^{(0)}$ 을 결정한 다음,

$$\theta^{(t+1)} = \theta^{(t)} - \frac{l'(\theta^{(t)})}{l''(\theta^{(t)})}$$

을 $t = 0, 1, 2, \dots$ 에 대해 진행하여 계속적으로 $\theta^{(t)}$ 를 업데이트하는 식으로 진행합니다. 대개 미리 정해진 충분히 작은 값(혹은 machine epsilon) ϵ 에 대하여, $\|\theta^{(t+1)} - \theta^{(t)}\| < \epsilon$ 이라면 반복을 종료하고 최종의 값을 근의 근사해로 사용하게 됩니다. Newton's method는 적절한 조건 하에서 매우 빠른 quadratic convergence를 가지어 실제 최대가능도추정량 $\hat{\theta}^{\text{MLE}}$ 에 대하여

$$\frac{\|\theta^{(t+1)} - \hat{\theta}^{\text{MLE}}\|}{\|\theta^{(t)} - \hat{\theta}^{\text{MLE}}\|^2} \rightarrow \text{const.}$$

역시 보장해 줄 수 있습니다.

그 아이디어는 테일러 전개로부터 시작합니다. 로그가능도의 미분계수에 대한 테일러 전개를 해보면,

$$0 = l'(\hat{\theta}^{\text{MLE}}) \approx l'(\theta^{(t)}) + l''(\theta^{(t)})(\hat{\theta}^{\text{MLE}} - \theta^{(t)})$$

이므로 잘 조합해 보면

$$\hat{\theta}^{\text{MLE}} \approx \theta^{(t)} - \frac{l'(\theta^{(t)})}{l''(\theta^{(t)})}$$

을 얻습니다. 즉 우변을 계속 반복하여 $\hat{\theta}^{\text{MLE}}$ 에 가까운 $\theta^{(t+1)}$ 들을 지속적으로 얻어가자는 것입니다.

$d > 1$ 인 다변량 상황의 경우에도 아이디어는 동일합니다. 테일러 전개의 형태는 동일하지만, l' 이 d 차원 벡터, l'' 이 $d \times d$ 행렬이라는 점이 다르기 때문에

$$\theta^{(t+1)} = \theta^{(t)} - (l''(\theta^{(t)}))^{-1}l'(\theta^{(t)})$$

으로 업데이트하면 됩니다. 특히 수치적으로 해를 찾는 경우, 해석적인 때와 다르게 l' 이나 l'' 을 직접 미분하는 대신 수치적 미분 방법들을 이용해 근사치로 사용할 수 있기 때문에, 분포가 복잡하더라도 크게 걱정할 필요가 없습니다.

그러나 Newton's method가 만능인 것만은 아닙니다. 로그가능도가 미분불가능할 수도 있고, 최대가능도추정량이 유일하지 않을 수도 있고, 항상 $l(\theta^{(t+1)}) \leq l(\theta^{(t)})$ 인 것이 보장되지도 않는 안정성 문제도 있습니다. 역행렬 연산이 포함되기 때문에 계산적으로도 부하가 꽤 있습니다. 우리는 아래에서 해석적인 해를 찾기는 불가능하고, Newton's method와 그 변형 형태를 이용하기 어려운 예시를 알아보려고 합니다.

2 Gaussian Mixture Model

어떤 지역에 k 개의 집성촌이 있다고 생각해 봅시다. 그리고 j 번째 집성촌 사람들의 키가 $N(\mu_j, \sigma_j^2)$ 이라는 정규분포를 따른다고 해 봅시다. 또한 전체 인구 중 k 번째 집성촌이 차지하는 비중이 w_j 라고 해 봅시다. 그렇다면 전체 지역에서 어떤 사람을 골랐을 때, 그 사람은 어떠한 집성촌 중 하나에 속할 것이고, 만약 그 정보를 알고 있다면 그 사람의 키에 대한 분포를 알 수 있습니다. 하지만 우리가 그 정보를 알 수 없다고 해 봅시다. 즉 그 사람이 속하는 집성촌은 우리가 직접 관측할 수 없는 **잠재 변수**(latent variable)입니다. i 번째 사람이 속하는 집성촌의 번호를 Z_i 라고 하면, 이 사람의 키 X_i 는 사실

$$X_i = I(Z_i = 1)W_{1i} + \dots + I(Z_i = k)W_{ki}, \quad W_{ji} \sim_{i.i.d.} N(\mu_j, \sigma_j^2)$$

처럼 쓸 수 있습니다. 즉 이 사람이 j 번째 집성촌에 속해 $Z_i = j$ 라면, X_i 는 W_{ji} 로써 실현되고, W_{ji} 는 평균이 μ_j 이고 분산이 σ_j^2 인 정규분포를 따라 결정됩니다. $P(Z_i = j) = w_j$ 임도 관찰할 수 있습니다.

또한 이를 아래처럼 조건부 분포를 이용해 쓰는 것도 가능합니다.

$$X_i|Z_i \sim N(\mu_{Z_i}, \sigma_{Z_i}^2)$$

그렇다면 조건부 확률을 이용하여

$$\begin{aligned} P(X_i \leq a) &= \sum_{j=1}^k P(X_i \leq a, Z_i = j) \\ &= \sum_{j=1}^k P(X_i \leq a | Z_i = j) P(Z_i = j) \\ &= \sum_{j=1}^k w_j \Phi\left(\frac{a - \mu_j}{\sigma_j}\right) \end{aligned}$$

임을 알고, 이로부터 X_i 의 pdf가

$$f(x) = \sum_{j=1}^k w_j \frac{1}{\sqrt{2\pi}\sigma_j} \exp\left(-\frac{(x - \mu_j)^2}{2\sigma_j^2}\right)$$

으로 k 개의 정규분포 확률밀도함수의 가중합이라는 사실 역시 관찰하실 수 있을 겁니다. 이처럼 어떤 분포가 몇 개의 정규분포로 구성되었다고 가정하여 모형화하는 방법을 **Gaussian Mixture Model(GMM)**이라고 합니다. GMM은 쉽게 설명하기 어려운 분포를 여러 개의 정규분포로 쪼개 나누어 설명할 수 있다는 장점이 있고, 정규분포 특성상 대외 커뮤니케이션에도 유용합니다. 또한 데이터들을 군집화(clustering)하는 데에도 이용되고 있습니다.




Figure 2: Gaussian Mixture Model 모식도. Source: Stackexchange

이를 벡터 버전으로 바꾸어도 동일합니다. $\mathbb{X}_i$ 가 d 차원 확률변수, $\mathbf{x}$ 는 d 차원 벡터, $\boldsymbol{\mu}_j$ 는 d 차원 상수벡터, Σ_j 는 $d \times d$ 차원 반양정치행렬이라고 하면 벡터 버전의 GMM은 확률밀도함수

$$f(\mathbf{x}) = \sum_{j=1}^k w_j \frac{1}{(2\pi)^{d/2} |\Sigma_j|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_j)^T \Sigma_j^{-1} (\mathbf{x} - \boldsymbol{\mu}_j)\right)$$

에 대응됩니다. 그러나 이를 설명하는 모수의 집합 $(w_1, \dots, w_k)$, $(\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_k)$ 과 $(\Sigma_1, \dots, \Sigma_k)$ 를 쉽게 찾기는 어렵습니다. 왜냐하면 단순히 $d = 1$, $k = 2$ 인 버전만 생각해 보아도 로그가능도가

$$l(w_1, w_2, \mu_1, \mu_2, \sigma_1^2, \sigma_2^2) = \sum_{i=1}^n \log\left(w_1 \frac{1}{\sqrt{2\pi}\sigma_1} \exp\left(-\frac{(x_i - \mu_1)^2}{2\sigma_1^2}\right) + w_2 \frac{1}{\sqrt{2\pi}\sigma_2} \exp\left(-\frac{(x_i - \mu_2)^2}{2\sigma_2^2}\right)\right)$$

으로 두 복잡한 식의 합의 로그의 합을 계산해야 하기 때문입니다. 일반적인 정규분포 하에서는 exp와 log가 상쇄되어 쉽게 계산할 수 있던 것과 대비됩니다. 또한 이 경우 $(w_1, \dots, w_k)$ 에서 k 개, $(\boldsymbol{\mu}_1, \dots, \boldsymbol{\mu}_k)$ 에서 dk 개, $(\Sigma_1, \dots, \Sigma_k)$ 에서 $\frac{d(d+1)}{2}k$ 개로 $O(d^2k)$ 개의 값을 추정해야 하는데, Newton's method에서 역행렬 연산을 하는 순간 $O(d^6k^3)$ 이라는 엄청난 계산적 부하를 마주합니다. 추가적으로 데이터가 어떠한 집성촌에서

비롯되었는지 알고 싶을 때, 즉 Z_i 를 추정하고 싶은 상황이라면 더욱 더 큰 문제가 됩니다. 이러한 Mixture model하에서 조금 더 쉽게 최대가능도를 달성할 수 있는 방법은 없을까요? 우리는 이를 위하여 아래에서 MM 알고리즘과 그 변형 형태인 EM 알고리즘에 대해 다루어 보려 합니다.

3 MM Algorithm

특정 함수(예를 들면, 가능도)의 최댓값을 구하기 위한 **MM 알고리즘**은 두 개의 M으로 구성됩니다. 첫째 M은 Minorization으로,

$$f(\mathbf{x}) \geq g(\mathbf{x}|\mathbf{x}^{(t)})$$

이라는 **dominance condition**과

$$f(\mathbf{x}^{(t)}) = g(\mathbf{x}^{(t)}|\mathbf{x}^{(t)})$$

이라는 **tangent condition**을 만족하는 **대리함수**(surrogate function) g 를 찾는 과정입니다. 즉 f 가 **최소한** g 보다는 큰 g 를 찾는 것입니다. 둘째 M은 Maximization으로, g 의 **최댓값**이 달성되는 값으로 $\mathbf{x}^{(t)}$ 를 업데이트합니다.

$$\mathbf{x}^{(t+1)} = \operatorname{argmax}_{\mathbf{x}} g(\mathbf{x}|\mathbf{x}^{(t)})$$




Figure 3: MM 알고리즘의 모식도. Notation은 살짝 다를 수 있음. Source: Coordinated Scheduling and Spectrum Sharing via Matrix Fractional Programming

이렇게 설정하면, $f(\mathbf{x}^{(t)})$ 에는 아래와 같은 **ascent property**가 존재하여 반복을 진행하면 안정적으로 더 큰 함수값을 얻어갈 수 있습니다.

$$f(\mathbf{x}^{(t+1)}) \geq g(\mathbf{x}^{(t+1)}|\mathbf{x}^{(t)}) \geq g(\mathbf{x}^{(t)}|\mathbf{x}^{(t)}) = f(\mathbf{x}^{(t)})$$

또한 굳이 g 의 최댓값을 찾을 필요 없이, 단지 $\mathbf{x}^{(t)}$ 보다 더 높은 g 값을 보장하는 $\mathbf{x}^{(t+1)}$ 을 이용해도 괜찮습니다. 이 알고리즘은 정확히 f 의 최댓값에 도달할 수 있다는 보장은 하지 않지만, 반복을 진행하면 f 의 값이 점점 증가하므로 좋은 조건 하에서 극댓값에는 도달할 수 있게 해줍니다. MM을 Minorization-Maximization 대신 Maximization-Minorization으로 바라보아 g 를 설정한다면, ascent property 대신 descent property가 성립하기 때문에 극솟값을 찾는 데에도 효과적으로 사용할 수 있습니다.

4 EM Algorithm

그렇다면 과연 이 대리함수 g 는 어떻게 찾을 수 있을까요? 다행히도, 우리가 앞서 살펴본 것처럼 잠재 변수가 존재하는 모형에서 f 를 로그 가능도 l 로 한다면, 대리함수 g 의 역할을 할 수 있는 Q 라는 함수를 구하는 방법이 쉽게 알려져 있습니다. 그리고 이를 이용하는 알고리즘을 바로 **EM 알고리즘**(Expectation-Maximization Algorithm)이라 부릅니다. 이제 우리가 관찰 가능한 데이터를 $\mathbf{o}$ (observed), 잠재변수를 $\mathbf{z}$ 라 하고, 관측된 데이터로부터 l 을 최대화하는 모수 θ 를 EM 알고리즘으로 어떻게 추정할 수 있을지 알아 보겠습니다.

EM 알고리즘의 기본적인 아이디어는, 관측 가능한 변수 $\mathbf{O}$ 만으로는 가능도함수가 복잡한 형태를 가지지만, 잠재변수 $\mathbf{Z}$ 를 추가하면 간단한 가능도함수를 얻을 수 있도록 하는 것입니다. 전체 자료에 대한 확률밀도함수를 $p_\theta(\mathbf{o}, \mathbf{z})$ 이라고 하면, 우리가 보게 되는 $\mathbf{o}$ 에 대한 주변로그가능도는

$$l(\theta) = \log \left(\int p_\theta(\mathbf{o}, \mathbf{z}) d\mathbf{z} \right)$$

로 쓸 수 있습니다. 그렇다면, 아래처럼 l 을 분해할 수 있게 됩니다.

$$\begin{aligned} l(\theta) &= \log \left(\int p_\theta(\mathbf{o}, \mathbf{z}) d\mathbf{z} \right) \\ &= \log \left(\int \frac{p_\theta(\mathbf{o}, \mathbf{z})}{p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o})} p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o}) d\mathbf{z} \right) \\ &= \log \left(\mathbb{E}_{\mathbf{Z}|\mathbf{O}}^{(t)} \left[\frac{p_\theta(\mathbf{O}, \mathbf{Z})}{p_{\theta^{(t)}}(\mathbf{Z}|\mathbf{O})} \right] \right) \\ &\geq \mathbb{E}_{\mathbf{Z}|\mathbf{O}}^{(t)} \left[\log \left(\frac{p_\theta(\mathbf{O}, \mathbf{Z})}{p_{\theta^{(t)}}(\mathbf{Z}|\mathbf{O})} \right) \right] \quad (\text{Jensen's Inequality}) \\ &\geq \int \log \left(\frac{p_\theta(\mathbf{o}, \mathbf{z})}{p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o})} \right) p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o}) d\mathbf{z} \\ &= \int \log(p_\theta(\mathbf{o}, \mathbf{z})) p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o}) d\mathbf{z} - \int \log(p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o})) p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o}) d\mathbf{z} \end{aligned}$$

이때 우리가 대리 함수로 사용할 함수가 바로

$$\int \log(p_\theta(\mathbf{o}, \mathbf{z})) p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o}) d\mathbf{z} - \int \log(p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o})) p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o}) d\mathbf{z}$$

입니다. 위의 식은 이 대리함수가 dominance condition을 만족시킴을 보여줍니다. 또한, Jensen's Inequality의 유일한 동치조건이

$$\frac{p_\theta(\mathbf{o}, \mathbf{z})}{p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o})}$$

가 $\mathbf{z}|\mathbf{o}$ 에 의존하지 않게 되는 것인데, 이는 $\theta = \theta^{(t)}$ 일 때

$$\frac{p_{\theta^{(t)}}(\mathbf{o}, \mathbf{z})}{p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o})} = \frac{p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o}) p_{\theta^{(t)}}(\mathbf{o})}{p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o})} = p_{\theta^{(t)}}(\mathbf{o})$$

으로 달성됩니다. 따라서 $l(\theta^{(t)}) = \int \log(p_{\theta^{(t)}}(\mathbf{o}, \mathbf{z})) p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o}) d\mathbf{z} - \int \log(p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o})) p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o}) d\mathbf{z}$ 이라는 tangent condition 역시 만족합니다. 이제 대리함수의 앞 항을

$$Q(\theta|\theta^{(t)}) := \int \log(p_\theta(\mathbf{o}, \mathbf{z})) p_{\theta^{(t)}}(\mathbf{z}|\mathbf{o}) d\mathbf{z} = \mathbb{E}_{\mathbf{Z}|\mathbf{O}}^{(t)}[\log p_\theta(\mathbf{O}, \mathbf{Z})]$$

을 정의하겠습니다. 또한 빠지는 항은 잘 들여다 보면 $\theta^{(t)}$ 에만 의존할 뿐, θ 와는 무관합니다. 따라서 우리는 대리 함수 전체를 최대화하는 θ 를 찾는 대신, 그냥 $Q(\theta|\theta^{(t)})$ 를 최대화하는 θ 를 찾으면 됩니다. 따라서 EM 알고리즘은 아래의 두 과정으로 이루어집니다.

- **(E-Step)** 조건부 기댓값 $Q(\theta|\theta^{(t)}) = \mathbb{E}_{\mathbf{Z}|\mathbf{O}}^{(t)}[\log p_\theta(\mathbf{O}, \mathbf{Z})]$ 를 계산한다.
- **(M-Step)** $\theta^{(t+1)} = \operatorname{argmax}_\theta Q(\theta|\theta^{(t)})$ 를 계산하여 업데이트한다.

이처럼 조건부 기댓값을 구한 뒤 그 최댓값을 구하는 과정을 t 에 대해 반복하여 수행하면, 로그가능도 $l(\theta)$ 를 점점 키워 나갈 수 있게 됩니다. MM 알고리즘에서와 마찬가지로 이것이 전체 최댓값을 보장하지는 않습니다만, 적절한 초깃값을 설정한다면 그를 달성하는 것도 가능합니다.

이제 마지막으로 GMM 하에서 EM 알고리즘이 어떻게 적용될 수 있는지 알아 보겠습니다. 앞서 본 관측 값들을 X_i 대신 O_i 로 쓰고, O_i 는 주어진 것으로 보도록 하겠습니다. 우리는 실제로 o_i 를 마주하고 최적화를 하기는 합니다. 여기에서 우리가 추정하고픈 모수는 $\theta = (w_1, \dots, w_k, \mu_1, \dots, \mu_k, \Sigma_1, \dots, \Sigma_k)$ 입니다. GMM에서 Q 를 구해 보면,

$$\begin{aligned} Q(\theta|\theta^{(t)}) &= \mathbb{E}_{\mathbf{Z}|\mathbf{O}}^{(t)}[\log p_{\theta}(\mathbf{O}, \mathbf{Z})] \\ &= \mathbb{E}_{\mathbf{Z}|\mathbf{O}}^{(t)}[\log(p_{\theta}(\mathbf{O}|\mathbf{Z})p_{\theta}(\mathbf{Z}))] \\ &= \mathbb{E}_{\mathbf{Z}|\mathbf{O}}^{(t)}\left[\sum_{i=1}^n \log\left(\frac{1}{(2\pi)^{d/2}|\Sigma_{Z_i}|^{1/2}} \exp\left(-\frac{1}{2}(O_i - \mu_{Z_i})^{\top}\Sigma_{Z_i}^{-1}(O_i - \mu_{Z_i})\right) w_{Z_i}\right)\right] \\ &= \sum_{i=1}^n \mathbb{E}_{Z_i|O_i}^{(t)}\left[-\frac{d}{2}\log(2\pi) - \frac{1}{2}\log(|\Sigma_{Z_i}|) - \frac{1}{2}(O_i - \mu_{Z_i})^{\top}\Sigma_{Z_i}^{-1}(O_i - \mu_{Z_i}) + \log(w_{Z_i})\right] \\ &= \sum_{i=1}^n \sum_{j=1}^k \frac{w_j^{(t)} \text{pdf}_{\text{Norm}}(O_i; \mu_j^{(t)}, \Sigma_j^{(t)})}{\sum_{s=1}^k w_s^{(t)} \text{pdf}_{\text{Norm}}(O_i; \mu_s^{(t)}, \Sigma_s^{(t)})} \left(-\frac{1}{2}\log(|\Sigma_j|) - \frac{1}{2}(O_i - \mu_j)^{\top}\Sigma_j^{-1}(O_i - \mu_j) + \log(w_j)\right) + C \end{aligned}$$

으로 E-Step이 조금 어렵게 구해지기는 합니다. $Z_i|O_i$ 의 확률질량함수는 베이지 법칙을 따라 위의 식에서처럼 결정됨을 주목하면 좋습니다. 특히 이 값은 i 번째 데이터 O_i 가 특정한 범례 j 에 속할 확률을 설명해 주기 때문에,

$$r_{i,j}^{(t)} := \frac{w_j^{(t)} \text{pdf}_{\text{Norm}}(O_i; \mu_j^{(t)}, \Sigma_j^{(t)})}{\sum_{s=1}^k w_s^{(t)} \text{pdf}_{\text{Norm}}(O_i; \mu_s^{(t)}, \Sigma_s^{(t)})}$$

를 **responsibility**라 부르고 이 점은 j 번째 범례에 해당 확률로 **soft-assigned**됩니다. 만약 결정적(deterministic)으로 군집화해야 한다면 그 값이 가장 큰 범례로 할당하면 되고, 확률적(probabilistic or stochastic)인 상황에서는 해당 확률로 배정해주면 됩니다.

한편 이를 이용하여 Q 를 표현하면,

$$Q(\theta|\theta^{(t)}) = \sum_{i=1}^n \sum_{j=1}^k r_{i,j}^{(t)} \left(-\frac{1}{2}\log(|\Sigma_j|) - \frac{1}{2}(O_i - \mu_j)^{\top}\Sigma_j^{-1}(O_i - \mu_j) + \log(w_j)\right) + C$$

으로 적절한 가중평균 형태가 되며 미분하기 아주 좋은 형태임을 알 수 있습니다. 즉 M-Step이 비교적 간편합니다. 먼저 각각의 비율 w_j 에 대해서는, $w_1 + w_2 + \dots + w_k = 1$ 이라는 제약이 있으므로 $w_k = 1 - w_1 - \dots - w_{k-1}$ 이라 하고 $j = 1, 2, \dots, k-1$ 에 대해서만 미분하면

$$\frac{\partial Q}{\partial w_j} = \sum_{i=1}^n \left(r_{i,j}^{(t)} \times \frac{1}{w_j} - r_{i,k}^{(t)} \times \frac{1}{w_k}\right) = 0, \quad j = 1, 2, \dots, k-1$$

이 일계조건으로 얻어집니다. 따라서

$$\frac{\sum_{i=1}^n r_{i,1}^{(t)}}{w_1} = \dots = \frac{\sum_{i=1}^n r_{i,k}^{(t)}}{w_k}$$

을 얻을 수 있으므로, 제약조건을 고려하면

$$w_j^{(t+1)} = \frac{\sum_{i=1}^n r_{i,j}^{(t)}}{\sum_{s=1}^k \left(\sum_{i=1}^n r_{i,s}^{(t)}\right)} = \frac{\sum_{i=1}^n r_{i,j}^{(t)}}{\sum_{i=1}^n \left(\sum_{s=1}^k r_{i,s}^{(t)}\right)} = \frac{1}{n} \sum_{i=1}^n r_{i,j}^{(t)}$$

으로 각 j 번째 범례에 대한 responsibility들의 합 중 해당 범례가 차지하는 비중이 업데이트해야 할 값이 됩니다. 일단 이것만 보더라도, k 개의 각 w 에 대해 열심히 이계미분까지 구해야 하는 Newton's method보다는 훨씬 쉽게 업데이트를 할 수 있을 것이라는 기대감이 듭니다.

둘째로 평균 μ_j 에 대해서는,

$$\frac{\partial Q}{\partial \mu_j} = \sum_{i=1}^n r_{i,j}^{(t)} \Sigma_j^{-1} (O_i - \mu_j) = 0$$

이므로 정리하면 Q 가 최대화되는 μ_j 는

$$\mu_j^{(t+1)} = \frac{\sum_{i=1}^n r_{i,j}^{(t)} O_i}{\sum_{i=1}^n r_{i,j}^{(t)}}$$

로 관측값 O_i 들에 대해 $r_{i,j}^{(t)}$ 에 비례하는 값으로 가중치를 하여 구한 가중평균입니다.

마지막으로 분산 Σ_j 에 대해서는, 트릭으로 그와 일대일 대응되는 Σ_j^{-1} 으로 미분하면

$$\frac{\partial Q}{\partial \Sigma_j^{-1}} = \sum_{i=1}^n r_{i,j}^{(t)} \left(\frac{1}{2} \Sigma_j - \frac{1}{2} (O_i - \mu_j)(O_i - \mu_j)^T \right) = 0$$

이 일계조건이므로

$$\Sigma_j^{(t+1)} = \frac{\sum_{i=1}^n r_{i,j}^{(t)} (O_i - \mu_j)(O_i - \mu_j)^T}{\sum_{i=1}^n r_{i,j}^{(t)}}$$

을 얻습니다. 즉 원래 우리가 표본평균과 분산을 구하는 데 사용하던 공식들에서, 그 가중치를 responsibility로만 바꾸면 간단히 모수들을 업데이트해나갈 수 있습니다. 그 다음에는 이 모수들을 이용해 $r_{i,j}^{(t+1)}$ 을 계산하고, 또다시 모수들을 업데이트하면 됩니다.

5 Example: Mixture of Pareto & Truncated Normal Dist.

굳이 정규분포들의 혼합 모형이 아니더라도, 우리가 알만큼 쉬운 분포들의 혼합 모형 하에서는 EM 모형을 여전히 간단히 적용할 수 있습니다. 어떤 마을에는 두 가지 집단이 있는데, 첫째 집단은 확률밀도함수가

$$f(x; \alpha) = \frac{\alpha}{(x + 0.9)^{\alpha+1}}, \quad x \geq 0.1$$

인 이동된 파레토 분포를 따르는 키를 가지고 있고, 둘째 집단은 확률밀도함수가

$$g(x; \mu, \sigma^2) = \frac{\frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)}{\int_{-\infty}^5 \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(w-\mu)^2}{2\sigma^2}\right) dw} = \frac{\phi\left(\frac{x-\mu}{\sigma}\right)}{\Phi\left(\frac{5-\mu}{\sigma}\right)}$$

인 절삭된 정규분포를 따른다고 합시다. 이러한 혼합 모형 하에서 두 집단의 비율 w_1, w_2 을 추정하고 각 관측값을 배정하기 위한 $r_{i,j}$ 를 결정하는 과정을 상상해 보겠습니다. 모수 θ 는 $\theta = (w_1, w_2, \alpha, \mu, \sigma^2)$ 입니다. GMM에서의 사례와 같이, responsibility는

$$r_{i,1}^{(t)} = \frac{w_1^{(t)} f(x_i; \alpha^{(t)})}{w_1^{(t)} f(x_i; \alpha^{(t)}) + w_2^{(t)} g(x_i; \mu, \sigma^2)}, \quad r_{i,2}^{(t)} = \frac{w_2^{(t)} g(x_i; \mu, \sigma^2)}{w_1^{(t)} f(x_i; \alpha^{(t)}) + w_2^{(t)} g(x_i; \mu, \sigma^2)}$$

으로 결정되며, Q 는

$$Q(\theta|\theta^{(t)}) = \sum_{i=1}^n \left(r_{i,1}^{(t)} \log(w_1 f(x_i; \alpha)) + r_{i,2}^{(t)} \log(w_2 g(x_i; \mu, \sigma^2)) \right)$$

으로 결정됩니다. 마찬가지로 미분하기 아주 좋은 형태이므로, 먼저 w_1 으로 미분하면 $w_2 = 1 - w_1$ 임에 따라

$$\frac{\partial Q}{\partial w_1} = \sum_{i=1}^n \left(\frac{r_{i,1}^{(t)}}{w_1} - \frac{r_{i,2}^{(t)}}{w_2} \right) = 0$$

이 일계조건이므로

$$w_1^{(t+1)} = \frac{1}{n} \sum_{i=1}^n r_{i,1}^{(t)}, \quad w_2^{(t+1)} = 1 - w_1^{(t+1)} = \frac{1}{n} \sum_{i=1}^n r_{i,2}^{(t)}$$

을 얻고, α 로 미분하면

$$\begin{aligned} \frac{\partial Q}{\partial \alpha} &= \sum_{i=1}^n r_{i,1}^{(t)} \frac{f_\alpha(x_i; \alpha)}{f(x_i; \alpha)} \\ &= \sum_{i=1}^n r_{i,1}^{(t)} \frac{1/(x_i + 0.9)^{\alpha+1} - \alpha \ln(x_i + 0.9)/(x_i + 0.9)^{\alpha+1}}{\alpha/(x_i + 0.9)^{\alpha+1}} \\ &= \sum_{i=1}^n r_{i,1}^{(t)} \left(\frac{1}{\alpha} - \ln(x_i + 0.9) \right) = 0 \end{aligned}$$

이 일계조건이므로

$$\alpha^{(t+1)} = \frac{\sum_{i=1}^n r_{i,1}^{(t)}}{\sum_{i=1}^n r_{i,1}^{(t)} \ln(x_i + 0.9)}$$

으로 업데이트한다. μ 로 미분하면

$$\begin{aligned} \frac{\partial Q}{\partial \mu} &= \sum_{i=1}^n r_{i,2}^{(t)} \frac{g_\mu(x_i; \mu, \sigma^2)}{g(x_i; \mu, \sigma^2)} \\ &= \sum_{i=1}^n r_{i,2}^{(t)} \frac{-\frac{(x_i - \mu)}{\sigma} \phi((x_i - \mu)/\sigma)/\sigma^2 \Phi((5 - \mu)/\sigma) + \phi((x_i - \mu)/\sigma) \phi((5 - \mu)/\sigma)/\sigma^2 \Phi^2((5 - \mu)/\sigma)}{\phi((x_i - \mu)/\sigma)/\sigma \Phi((5 - \mu)/\sigma)} \\ &= \sum_{i=1}^n r_{i,2}^{(t)} \left(-\frac{(x_i - \mu)}{\sigma^2} + \frac{\phi((5 - \mu)/\sigma)}{\sigma \Phi((5 - \mu)/\sigma)} \right) \\ &= \frac{1}{\sigma^2} \left(\left(\sum_{i=1}^n r_{i,2}^{(t)} \right) \left(\mu + \frac{\sigma \phi((5 - \mu)/\sigma)}{\Phi((5 - \mu)/\sigma)} \right) - \sum_{i=1}^n r_{i,2}^{(t)} x_i \right) = 0 \end{aligned}$$

이 일계조건이므로 GMM과 달리 쉽게 업데이트하기 어렵습니다. 여기에서는 초기값이 적절히 설정되어 업데이트가 진행된다면 $\mu^{(t+1)} \approx \mu^{(t)}$, $(\sigma^2)^{(t+1)} \approx (\sigma^2)^{(t)}$ 일 것이라 가정하고

$$\mu^{(t+1)} = \frac{\sum_{i=1}^n r_{i,2}^{(t)} x_i}{\sum_{i=1}^n r_{i,2}^{(t)}} - \frac{\sigma^{(t)} \phi((5 - \mu^{(t)})/\sigma^{(t)})}{\Phi((5 - \mu^{(t)})/\sigma^{(t)})}$$

으로 대안적인 업데이트를 해볼 수 있습니다. 마지막으로 σ^{-2} 로 미분시

$$\begin{aligned} \frac{\partial Q}{\partial \sigma^{-2}} &= \sum_{i=1}^n r_{i,2}^{(t)} \frac{g_{\sigma^{-2}}(x_i; \mu, \sigma^2)}{g(x_i; \mu, \sigma^2)} \\ &= \sum_{i=1}^n r_{i,2}^{(t)} \left(\frac{1}{2} \sigma^2 - \frac{1}{2} (x_i - \mu)^2 - \frac{1}{2} (5 - \mu) \frac{\sigma \phi((5 - \mu)/\sigma)}{\Phi((5 - \mu)/\sigma)} \right) \end{aligned}$$

이므로, 앞과 같은 가정 하에서

$$(\sigma^2)^{(t+1)} = \frac{\sum_{i=1}^n r_{i,2}^{(t)} (x_i - \mu^{(t+1)})^2}{\sum_{i=1}^n r_{i,2}^{(t)}} + (5 - \mu^{(t+1)}) \frac{\sigma^{(t)} \phi((5 - \mu^{(t+1)})/\sigma^{(t)})}{\Phi((5 - \mu^{(t+1)})/\sigma^{(t)})}$$

으로 업데이트하는 것을 고려해볼 수 있습니다. 이를 충분히 수렴할 때까지, 즉

$$\|\theta^{(t+1)} - \theta^{(t)}\|_{\infty} < \epsilon$$

정도일 까지 수행한 다음 수렴하는 $w_1, w_2, \alpha, \mu, \sigma^2$ 을 구하고, 이를 바탕으로 최종적인 responsibility $r_{i,1}$ 과 $r_{i,2}$ 를 구하면 이를 i 번째 개체가 파레토 분포(혹은 절삭 정규분포)로부터 비롯되었을 확률로 생각하고 확률적인 배정을 해줄 수 있게 될 것입니다.

References

- [1] A. P. Dempster, N. M. Laird, and D. B. Rubin, “Maximum likelihood from incomplete data via the em algorithm,” *Journal of the royal statistical society: series B (methodological)*, vol. 39, no. 1, pp. 1–22, 1977.
- [2] L. E. Baum, T. Petrie, G. Soules, and N. Weiss, “A maximization technique occurring in the statistical analysis of probabilistic functions of markov chains,” *The annals of mathematical statistics*, vol. 41, no. 1, pp. 164–171, 1970.
- [3] K. Lange, D. R. Hunter, and I. Yang, “Optimization transfer using surrogate objective functions,” *Journal of computational and graphical statistics*, vol. 9, no. 1, pp. 1–20, 2000.